Universidad César Vallejo

FACULTAD DE INGENIERÍA Y ARQUITECTURA

ESCUELA PROFESIONAL DE INGENIERÍA DE SISTEMAS

Modelo de machine learning para predecir la demanda diaria por categoría de producto en minimarket del distrito de Comas 2026

Tesis para obtener el título profesional de:

Ingeniería de Sistemas

Autor :

Guerrero Mora, Carlos David Elian (orcid.org/0000-0002-2045-0688)

Asesor(a)(es):

Mg. Perez Farfan, Ivan Martin (orcid.org/0000-0001-5833-9400)

Línea de investigación:

Sistemas de Información y Comunicaciones

Línea de responsabilidad social universitaria:

Innovación Tecnológica y Transformación Digital

LIMA – PERÚ

2026

Declaratoria de autenticidad del asesor

UNIVERSIDAD CÉSAR VALLEJO

FACULTAD DE INGENIERÍA Y ARQUITECTURA
ESCUELA PROFESIONAL DE INGENIERÍA DE SISTEMAS

Declaratoria de Autenticidad del Asesor

Yo, PEREZ FARFAN IVAN MARTIN, docente de la FACULTAD DE INGENIERÍA Y ARQUITECTURA de la escuela profesional de INGENIERÍA DE SISTEMAS de la UNIVERSIDAD CÉSAR VALLEJO SAC - LIMA NORTE, asesor de Proyecto de Investigación titulado: "Modelo de machine learning para predecir la demanda diaria por categoría de producto en minimarket del distrito de Comas 2026", cuyo autor es GUERRERO MORA CARLOS DAVID ELIAN, constato que la investigación tiene un índice de similitud de %, verificable en el reporte de originalidad del programa Turnitin, el cual ha sido realizado sin filtros, ni exclusiones.

He revisado dicho reporte y concluyo que cada una de las coincidencias detectadas no constituyen plagio. A mi leal saber y entender el Proyecto de Investigación cumple con todas las normas para el uso de citas y referencias establecidas por la Universidad César Vallejo.

En tal sentido, asumo la responsabilidad que corresponda ante cualquier falsedad, ocultamiento u omisión tanto de los documentos como de información aportada, por lo cual me someto a lo dispuesto en las normas académicas vigentes de la Universidad César Vallejo.

LIMA, 04 de Julio del 2026

Apellidos y Nombres del Asesor:	Firma
PEREZ FARFAN IVAN MARTIN **DNI:** 08647541 **ORCID:** 0000-0001-5833-9400	Firmado electrónicamente por: IPEREZFA el 04-07-2026 19:29:50

Código documento Trilce: TRI - 1377584

INVESTIGA UCV

Declaratoria de originalidad del autor

UNIVERSIDAD CÉSAR VALLEJO

FACULTAD DE INGENIERÍA Y ARQUITECTURA

ESCUELA PROFESIONAL DE INGENIERÍA DE SISTEMAS

Declaratoria de Originalidad del Autor

Yo, GUERRERO MORA CARLOS DAVID ELIAN estudiante de la FACULTAD DE INGENIERÍA Y ARQUITECTURA de la escuela profesional de INGENIERÍA DE SISTEMAS de la UNIVERSIDAD CÉSAR VALLEJO SAC - LIMA NORTE, declaro bajo juramento que todos los datos e información que acompañan el Proyecto de Investigación titulado: "Modelo de machine learning para predecir la demanda diaria por categoría de producto en minimarket del distrito de Comas 2026", es de mi autoría, por lo tanto, declaro que el Proyecto de Investigación:

1. No ha sido plagiado ni total, ni parcialmente.
2. He mencionado todas las fuentes empleadas, identificando correctamente toda cita textual o de paráfrasis proveniente de otras fuentes.
3. No ha sido publicado, ni presentado anteriormente para la obtención de otro grado académico o título profesional.
4. Los datos presentados en los resultados no han sido falseados, ni duplicados, ni copiados.

En tal sentido asumo la responsabilidad que corresponda ante cualquier falsedad, ocultamiento u omisión tanto de los documentos como de la información aportada, por lo cual me someto a lo dispuesto en las normas académicas vigentes de la Universidad César Vallejo.

Nombres y Apellidos	**Firma**
CARLOS DAVID ELIAN GUERRERO MORA **DNI:** 71926970 **ORCID:** 0000-0002-2045-0688	Firmado electrónicamente por: CGUERREROM el 04-07-2026 19:50:00

Código documento Trilce: TRI - 1377236

INVESTIGA UCV

Dedicatoria

Agradecimiento

Índice de contenidos

Caratula……i
Declaratoria de autenticidad del asesor.....ii
Declaratoria de originalidad del autor iii
Dedicatoria.....iv
Agradecimiento..... v
Índice de contenidos.....vi
Índice de tablas..... viii
Índice de figuras ix
Resumen x
Abstract.....xi
I. Introducción 1
II. Metodología 12
III. Resultados..... 16
IV. Discusión..... 17
V. Conclusiones..... 18
VI. Recomendaciones..... 19
Referencias..... 20
Anexos..... 25

Índice de tablas

Índice de figuras

Fig. 1. Formula mape [3]. 2

Resumen

Abstract

I. Introducción

En los últimos años, la gestión de la demanda se convirtió en una necesidad relevante para los negocios dedicados a la comercialización de productos de consumo diario, debido al comportamiento de compra de los clientes presentó variaciones constantes y difíciles de anticipar mediante métodos tradicionales. En el sector retail, estas variaciones se observaron con mayor claridad en empresas que manejaron diversos productos, categorías, precios, promociones y temporadas de venta. Esta situación afectó especialmente a pequeños negocios, como bodegas, tiendas y minimarkets, debido a que muchas de sus decisiones de compra, reposición y abastecimiento continuaron dependiendo de la experiencia del encargado o de revisiones manuales de las ventas.

En ese contexto, la predicción de la demanda pasó a ser una herramienta clave para disminuir la incertidumbre y optimizar la planificación de productos dentro del negocio. Las fallas o errores operativos de los empleados en los puntos de venta (POS) representan el 24% de las diferencias de inventario en la industria minorista. [1].

La problemática de la demanda no estuvo relacionada únicamente con vender una mayor o menor cantidad de productos, sino también con factores importantes como la disponibilidad del inventario, la satisfacción de los clientes y el uso eficiente de los recursos del negocio. Cuando un minimarket no lograba estimar de manera aproximada la cantidad de productos que serían solicitados en un determinado periodo, podían generarse distintas dificultades en la operación diaria. Por un lado, el exceso de productos ocasionaba acumulación de mercadería, vencimiento de artículos perecibles, uso innecesario de espacio y pérdidas económicas.

Por otro lado, la escasez de productos provocaba quiebres de stock, pérdida de ventas e incluso la posibilidad de que los clientes optaran por acudir a otros establecimientos. Considerando que en estudios del sector se ha identificado que los errores operativos en los puntos de venta representan el 24% de las diferencias de inventario [1], [3]. Donde el uso de modelos de Machine Learning ha demostrado reducir las tasas de error de pronóstico (WMAPE) en rangos significativos, alcanzando mejoras de precisión de hasta un 4.779% frente a 2 métodos tradicionales [1], [2], [3].

Debido a ello, la predicción de la demanda diaria por categoría de producto se convirtió en una necesidad importante para este tipo de negocios, ya que permitió mejorar la organización de las compras y responder de manera más adecuada al comportamiento de los consumidores.

$$MAPE = \frac{1}{N}\sum_{i=1}^{N}\frac{|y_i - \hat{y_i}|}{y_i}.100\%$$

Fig. 1. *Formula MAPE [3].*

A nivel internacional, el uso de machine learning en el sector retail adquirió una mayor importancia debido a su capacidad para analizar datos históricos de ventas e identificar patrones que muchas veces no podían detectarse fácilmente mediante procedimientos manuales. Brackmann, Friedrich y Urbach [1] destacan que el machine learning ofrece un abanico de soluciones muy prácticas para el sector retail, especialmente al momento de administrar las ventas, el inventario y la rutina operativa diaria. Esto demuestra que los modelos predictivos funcionan como un respaldo real para que cualquier comercio mejore su dinámica interna, aunque el éxito de estos pronósticos no pasa solamente por tener el algoritmo más avanzado.

Para que la herramienta realmente funcione, es obligatorio hacer un trabajo de fondo que implica limpiar a detalle la base de datos histórica, clasificar los productos con lógica y tener la habilidad administrativa para traducir esos cálculos en verdaderas acciones de compra o reposición en la tienda. Una vez que se realiza correctamente toda esta preparación técnica, arquitecturas más complejas como las Redes Neuronales Profundas (DNN) logran sacar a relucir todo su potencial, llegando a superar en precisión hasta en un 35 % a los métodos estadísticos convencionales como el Promedio Móvil, el método de Croston, ARIMA o el Suavizado Exponencial [4].

En este mismo sentido, el trabajo de Wang y Luo [2] resulta clave, ya que ellos armaron un método para proyectar las ventas dividiendo los productos por categorías a través de modelos como CatBoost, Decision Tree y XGBoost. Tomar en cuenta este antecedente es muy útil para nuestro proyecto porque 3 aborda justo lo que buscamos hacer: predecir cómo se moverá la mercadería según su grupo o familia, lo cual encaja perfectamente con el objetivo del estudio. Sumado a esto, los resultados que obtuvieron demostraron que el uso de machine learning realmente logró generar estimaciones más precisas y útiles para la planificación comercial y la gestión del inventario.

En el caso de un minimarket, la demanda no se comportó igual en todas las áreas del negocio. Por ejemplo, categorías como bebidas, abarrotes, productos de limpieza, golosinas o artículos de primera necesidad pudieron variar según el día de la semana, la temporada, los precios o los hábitos de compra de los clientes. Por esta razón, analizar solo las ventas totales del negocio no resultó suficiente para tomar decisiones específicas sobre reposición y planificación de productos. La predicción por categoría permitió una visión más detallada y útil para la gestión diaria del establecimiento. El método híbrido propuesto logró una mejora media en el desempeño de

aproximadamente un 4% en comparación con los tres métodos tradicionales evaluados [2].

El análisis estadístico reveló que la distribución Exponencial-Poisson puede generar valores cercanos a las ventas reales con un margen de error inferior al 7% [4]. Superaron a los métodos tradicionales en un rango del 9% al 35% en términos de error cuadrático medio (MSE) [4]. Asimismo, Auppakorn y Phumchusri [3] propusieron métodos para el pronóstico de ventas diarias en negocios retail con productos de distintas categorías y precios variables. Este antecedente se relacionó directamente con el tema de investigación, ya que trabajó con ventas diarias, categorías de productos y un entorno comercial minorista. En el caso de un minimarket, la demanda diaria pudo variar considerablemente entre días laborables, fines de semana, fechas de pago, campañas escolares, feriados o temporadas de mayor consumo.

Debido a ello, una estimación mensual o general pudo resultar poco precisa para orientar decisiones de compra a corto plazo. En cambio, la predicción diaria ofreció una referencia más cercana a la realidad operativa del negocio. El problema también estuvo relacionado con la presencia de productos con demanda irregular. Ahmadov et al. [4] abordaron la predicción de ventas 4 intermitentes mediante técnicas de deep learning, resaltando la dificultad de anticipar el comportamiento de productos que no se vendieron todos los días o que presentaron patrones de consumo variables. Este aspecto resultó importante para los minimarkets, ya que no todas las categorías tuvieron la misma frecuencia de rotación.

Mientras algunos productos pudieron venderse diariamente, otros dependieron de necesidades ocasionales, promociones o cambios en las preferencias de los consumidores. En consecuencia, un modelo de predicción debió considerar que la demanda de determinadas categorías podía presentar una alta variabilidad y no seguir siempre patrones simples o constantes, ya que el comportamiento de compra de los consumidores pudo cambiar según distintos factores Las entrevistas realizadas tuvieron una duración promedio de 59 minutos [5]. Las fallas o errores operativos de los empleados en los puntos de venta (POS) representan el 24% de las diferencias de inventario en la industria minorista [5]. Otro factor que influyó en la demanda dentro del sector retail fue el contexto externo.

Chan y Wahab [5] analizaron el impacto de las condiciones climáticas en las ventas mediante técnicas de machine learning, demostrando que factores como el calor, el frío o las lluvias podían influir en el comportamiento de compra de los consumidores. Este aspecto es relevante para un minimarket ubicado en Comas, ya que la demanda de algunas categorías, como bebidas, helados, productos de limpieza y alimentos de consumo rápido, puede variar según las condiciones climáticas y la temporada del año. Por ello, la presente investigación busca estimar la demanda diaria a partir del análisis del historial de ventas de cada categoría de producto.

Sin embargo, la salida de los productos no depende únicamente de la información registrada en el minimarket. También existen factores externos que pueden modificar las decisiones de compra de los consumidores y que no siempre aparecen reflejados en los registros de los puntos de venta (POS). Por esta razón, futuras investigaciones podrían incluir estas variables para mejorar la capacidad de los modelos al momento de estimar la demanda.

Asimismo, desde la perspectiva de la Inteligencia Artificial Explicable (XAI), distintos estudios señalan que las características físicas y comerciales de los productos pueden influir en su nivel de venta. En un minimarket, elementos como el tamaño del envase, la presentación o la forma en que cada artículo es registrado en el sistema suelen formar parte de la gestión cotidiana. Sin embargo, al momento de desarrollar un modelo de pronóstico, estas características pueden convertirse en variables útiles para comprender mejor el comportamiento de la demanda.

En el caso del Minimarket Taully, ello pone de manifiesto que, antes de implementar un modelo de machine learning, es necesario revisar, organizar y depurar el catálogo de productos para disponer de información comercial consistente y confiable De esta manera, el proceso de predicción se fundamentará en datos correctamente estructurados, favoreciendo un entrenamiento más adecuado del modelo y una estimación más precisa de la demanda. Si juntamos los productos de forma desordenada o simplemente como el encargado está acostumbrado a ubicarlos en los estantes, el sistema va a recibir información cruzada durante su fase de entrenamiento. El resultado de este error es que el algoritmo nunca logrará identificar los verdaderos patrones de consumo de los clientes.

Por este motivo, estimar cuánto se va a vender va mucho más allá de aplicar una ecuación matemática; la verdadera clave está en hacer el trabajo previo de depurar, organizar y estructurar toda la base de datos del local para que la computadora procese información limpia y apegada a la realidad.
A nivel local, también logramos identificar distintos trabajos de investigación enfocados en aplicar el machine learning para solucionar problemas reales de ventas, inventario y cálculo de la demanda. Un referente directo de esto es el proyecto desarrollado en la Universidad Tecnológica del Perú [7], donde estructuraron un modelo dedicado específicamente a predecir la necesidad de mercadería dentro de un minimarket basándose en este tipo de técnicas predictivas.

Este antecedente se relacionó directamente con el presente estudio, ya que abordó un contexto similar y demostró que este tipo de 6 modelos también pudo aplicarse en pequeños negocios comerciales. Este aporte permitió evidenciar que el problema de anticipar la demanda no fue exclusivo de grandes cadenas comerciales, sino que también afectó a pequeños y medianos negocios del contexto peruano. Sin embargo, se debió considerar que cada minimarket presentó características particulares en cuanto a ubicación, tipo de clientes, variedad de productos, frecuencia de compra y

nivel de digitalización. Por ello, los resultados obtenidos en otros estudios no pudieron aplicarse automáticamente al caso del minimarket en estudio sin realizar previamente un análisis de sus propios datos.

Palomino Huarilloclla [8] implementó un modelo de machine learning para la predicción de la demanda en una ferretería de Moquegua, relacionando la predicción con la gestión de inventarios y la toma de decisiones dentro de una empresa comercial local. Aunque una ferretería no perteneció al mismo rubro que un minimarket, ambos negocios compartieron una dificultad similar: anticipar qué productos serían más solicitados y en qué momento sería necesario reponerlos. Este antecedente permitió sostener que los modelos predictivos pudieron adaptarse a distintos tipos de negocios, siempre que existiera información histórica suficiente y una adecuada selección de variables.

En el caso del minimarket en estudio, dicha adaptación resultó necesaria debido a que el comportamiento de compra estuvo asociado a productos de consumo frecuente y a categorías con diferentes niveles de rotación. Montero López [9] propuso un sistema web inteligente basado en machine learning para mejorar la gestión y el análisis de información relacionada con las ventas, la demanda y el inventario de una empresa. Este estudio fue relevante porque relacionó los modelos predictivos con el control de stock y demostró que la predicción pudo aplicarse a necesidades concretas de gestión.

En el caso de un minimarket, un modelo predictivo no solo permitiría estimar cantidades futuras, sino también apoyar decisiones sobre compras, reposición, almacenamiento y disponibilidad de productos. Desde esta perspectiva, el machine learning pudo ayudar a reducir decisiones improvisadas y fortalecer una gestión basada en datos. Ponce Illacutipa [10] desarrolló un modelo basado en machine learning para optimizar el pronóstico de ventas de la empresa Ricos Pan durante el periodo 2020-2021.

Este estudio mostró que las técnicas de aprendizaje automático pudieron mejorar la estimación de ventas y servir como apoyo para la toma de decisiones en una empresa comercial. Asimismo, demostró la importancia de trabajar con datos históricos para identificar patrones de comportamiento en las ventas y obtener proyecciones más precisas. Este estudio aportó al presente trabajo al evidenciar que el pronóstico de ventas pudo utilizarse como una herramienta para estimar la demanda en negocios del contexto peruano. Aunque el rubro de panificación presentó características distintas al de un minimarket, ambos contextos compartieron la necesidad de anticipar el comportamiento de compra para evitar pérdidas por exceso de producción, falta de productos o mala planificación.

Flores Taquiri y Montalvo Celis [11] analizaron el uso de machine learning para mejorar la predicción en la gestión de inventario dirigida a PYMES de venta de productos tecnológicos. Su investigación fue útil porque abordó el problema desde la

realidad de pequeñas y medianas empresas, donde muchas decisiones continuaron dependiendo de registros básicos, hojas de cálculo o criterios empíricos. Esta situación fue cercana al contexto de un minimarket, donde la falta de herramientas predictivas pudo limitar la planificación de compras y ocasionar errores en la reposición.

Sin embargo, también se reconoció que la aplicación de machine learning en una PYME exigió condiciones mínimas, como disponibilidad de datos históricos, categorización correcta de productos y evaluación objetiva del desempeño del modelo. León Villavicencio y Vinces Chumbes [12] aplicaron machine learning para la gestión de ventas en la empresa Forever Group SAC, considerando la predicción de ingresos y cantidades vendidas. Este antecedente permitió observar que las técnicas de aprendizaje automático pudieron apoyar el análisis comercial en empresas peruanas. Asimismo, Anchante Aybar y Fernández Chávez [13] estudiaron el machine learning para la toma de decisiones en la gestión de ventas en Lima, reforzando la idea de que los modelos predictivos no solo tuvieron valor técnico, sino también valor 8 administrativo.

Rojas Vilca [14] desarrolló un aplicativo móvil con machine learning para la gestión de ventas en productos de una empresa de Lima, relacionando tecnología, productos, ventas y modelos predictivos dentro de una solución aplicada. Serna Berrocal [15] planteó un modelo de machine learning para predecir las ventas de una empresa retail, y González Jauregui y Mariscal Cruzado [16] propusieron mejoras basadas en machine learning, Big Data y DDMRP para optimizar el cumplimiento del pronóstico en una empresa de bienes de consumo. Separa Desde el enfoque teórico, el machine learning se entiende como una rama de la inteligencia artificial orientada al desarrollo de modelos capaces de aprender patrones a partir de datos históricos para realizar predicciones o clasificaciones.

En el caso de la predicción de demanda, el aprendizaje automático permite utilizar registros históricos de ventas para estimar comportamientos futuros. Padmanabham [17] propone un marco de machine learning para el pronóstico de ventas en el sector retail, considerando etapas como el preprocesamiento de datos, el análisis exploratorio, la ingeniería de características y la comparación de modelos de regresión. Este enfoque resulta importante para el presente estudio, porque muestra que el rendimiento de un modelo no depende solo del algoritmo seleccionado, sino también de la preparación adecuada de los datos, la calidad de la información utilizada y la correcta selección de variables para el proceso de predicción.

Mustapha y Sithole [18] evalúan modelos como Random Forest, XGBoost, regresión lineal y ARIMA para el pronóstico de ventas en el sector retail, comparando métodos tradicionales con modelos basados en machine learning. Este antecedente muestra que la elección de un modelo no debe depender solo de qué tan complejo fuera, sino también de su desempeño, su facilidad de interpretación y su relación con el problema de estudio. En algunos casos, un modelo sencillo puede brindar resultados aceptables

y fáciles de comprender. En otros, los modelos más robustos pueden reconocer relaciones no lineales y mejorar la precisión de las predicciones. Por ello, en el 0presente estudio se considera la comparación de diferentes modelos y el uso de métricas de evaluación, con el fin de determinar cuál se ajusta mejor a 9 los datos del minimarket en estudio y ofrece mejores resultados para la predicción de la demanda.

Mansur, Ahmed e Islam [19] presentan modelos híbridos basados en redes neuronales y técnicas de machine learning para predecir ventas en tiendas retail, demostrando que la combinación de distintos métodos puede mejorar la precisión del pronóstico. De manera similar, Ahmed, Khan y Ali [20] comparan algoritmos de deep learning, como CNN, LSTM, MLP y modelos híbridos, aplicados al pronóstico de ventas en el sector retail. Estos aportes muestran que existen métodos avanzados para trabajar problemas de forecasting y predicción de demanda. Sin embargo, en el contexto de un minimarket, el uso de modelos complejos debe evaluarse con cuidado, ya que el modelo más avanzado no siempre es el más adecuado para las necesidades del negocio.

Por ello, la elección del modelo debe considerar la cantidad de datos disponibles, la facilidad de implementación y la posibilidad de interpretar los resultados para apoyar la toma de decisiones comerciales. La relación entre la predicción de la demanda y la gestión de inventario es importante en los negocios retail, porque ambas áreas influyen en la disponibilidad de productos y en el uso adecuado de los recursos. Liu, Kalaitzi, Wang y Papanagnou [21] desarrollan un enfoque basado en machine learning para predecir quiebres de stock, relacionando el comportamiento de la demanda con la disponibilidad de productos en el sector retail. Este aporte es relevante porque muestra que anticipar la demanda pudo ayudar a reducir situaciones de desabastecimiento y mejorar la disponibilidad de productos.

En el caso del minimarket en estudio, la predicción diaria por categoría permite identificar las categorías con mayor riesgo de quiebre de stock, y facilita una mejor planificación de compras y reposición de productos. De esta manera, el modelo no solo tiene valor estadístico, sino también una utilidad práctica en las operaciones diarias del negocio. Por otra parte, al enfocarnos en la mercadería que recién ingresa a la tienda y carece de un historial amplio, resulta muy útil el estudio de Sousa, Moreira y Ferreira [22], quienes aplican machine learning para proyectar la demanda de estos nuevos artículos en el sector minorista. Sobre este mismo punto, 10 Wang, Chen y Lin [23] proponen una forma de calcular esta demanda dividiendo el análisis en dos etapas, mientras que Hwang, Kim y Park [24] optan por apoyarse en técnicas de clustering y ensemble learning para afinar mucho más esos pronósticos.

En conjunto, estas investigaciones muestran que un modelo predictivo no debería centrarse únicamente en productos que ya cuentan con un historial de ventas estable. Cuando un establecimiento incorpora un nuevo producto o amplía su oferta comercial, las primeras ventas pueden no reflejar con claridad el comportamiento habitual de la demanda. Por ello, resulta conveniente utilizar métricas complementarias que

permitan observar cómo evoluciona el comportamiento de estos productos a medida que ganan presencia en el mercado. En cuanto a las condiciones del entorno físico, Hu et al. [25] demostraron, mediante el uso de AutoML y técnicas de inteligencia geoespacial, que la ubicación geográfica puede influir de manera importante en las tendencias de compra de los consumidores.

Este planteamiento también puede observarse en el distrito de Comas, donde la rotación del inventario no depende solo de la cantidad de productos disponibles en el minimarket. También puede verse influida por factores externos, como la presencia de otros establecimientos comerciales, el flujo de personas y los hábitos de consumo de la población. A ello se suma el avance de los sistemas computacionales, que actualmente permiten procesar mayores volúmenes de información e incorporar diferentes variables en los modelos utilizados para estimar la demanda.

En este sentido, Shahzad, Khan y Ullah [26] indican que algoritmos como el Temporal Fusion Transformer pueden obtener buenos resultados en la predicción de la demanda dentro del sector minorista. Esto se alinea bastante con la postura de Seyam, Islam y Hossain [27], quienes destacan que calcular la demanda apoyándose en machine learning y deep learning es un campo de investigación que sigue más vigente que nunca. Al final del día, todos estos referentes técnicos nos dejan claro que aún tenemos un margen enorme para seguir innovando y perfeccionando la manera en que proyectamos las ventas para este tipo de negocios.

A pesar de todo el avance tecnológico actual, en la práctica es muy común ver que los pequeños negocios siguen sin aprovechar las herramientas predictivas 11 para definir su rumbo comercial. Por lo general, estos locales cumplen con registrar sus ventas del día a día en el sistema, pero al final toda esa información termina archivada sin que nadie le dé un uso analítico real. Precisamente, esta carencia de herramientas analíticas representa una oportunidad para aplicar técnicas de machine learning en un entorno operativo real. Al implementar este modelo en el minimarket objeto de estudio, el algoritmo no se limitará a procesar registros históricos de manera pasiva; su función principal será transformar dicha base de datos en un motor activo capaz de proyectar la demanda diaria para cada línea de productos.

De esta forma, el establecimiento dará un salto de calidad en sus operaciones dará un salto de calidad enorme en sus operaciones, abandonando esa vieja costumbre de comprar mercadería guiándose solo por presentimientos para empezar a tomar decisiones firmes basadas íntegramente en sus propios datos. Llevando este problema a nuestra realidad, el escenario central de la investigación es un minimarket ubicado en el distrito de Comas. Hablamos de un emprendimiento que está creciendo, pero que hoy en día tropieza con el gran reto de manejar niveles de venta que suben y bajan bruscamente dependiendo del tipo de producto. Esta variación en las ventas complica la organización de los pedidos y la reposición de los productos en los anaqueles. En la actualidad, el inventario se repone principalmente según la

experiencia del responsable del minimarket y mediante la revisión visual de los niveles de stock.

Aunque este método puede funcionar durante las primeras etapas del negocio, pierde efectividad conforme aumenta la variedad de productos, debido a que cada categoría presenta un comportamiento de venta distinto. A partir de los registros del sistema Kardex se identificó un desequilibrio en la gestión del inventario: los productos de mayor rotación suelen agotarse con frecuencia, mientras que los de menor demanda o aquellos de carácter perecible permanecen almacenados por más tiempo.

Esta situación genera costos por mantener productos sin movimiento y, a la vez, puede reducir las oportunidades de venta. Frente a ello, un modelo de machine learning permitiría analizar el historial de transacciones y estimar con mayor precisión la cantidad de productos que debería solicitarse en cada categoría. De esta manera, sería posible mejorar la planificación del inventario y apoyar una gestión más eficiente de las operaciones del minimarket. La falta de herramientas predictivas, en cambio, limita la capacidad del establecimiento para anticipar la demanda.

Cuando las proyecciones de ventas no reflejan con precisión el comportamiento de la demanda, la distribución de los recursos puede verse afectada. Esto puede ocasionar acumulación de productos de baja rotación y, al mismo tiempo, falta de stock en aquellos con mayor demanda. Estas situaciones también repercuten en la experiencia del cliente, ya que no encontrar determinados productos puede afectar su percepción sobre el servicio. Por ello, contar con estimaciones más precisas permite organizar mejor las compras, mantener un mayor control del inventario y tomar decisiones más acertadas dentro del minimarket.

Desde el punto de vista administrativo, el principal desafío para garantizar la sostenibilidad del negocio radica en contar con información confiable que permita anticipar el comportamiento de la demanda y respaldar una adecuada planificación de las compras, el abastecimiento y la gestión del inventario supera la gestión operativa básica de ventas. El éxito comercial reside en la capacidad de disponer de información precisa que permita anticipar el comportamiento de los clientes frente a diversas categorías de productos. Contar con esta ventaja competitiva proporciona el margen de maniobra necesario para la toma de decisiones estratégicas, evitando que la gestión del negocio se vea limitada por situaciones de urgencia.

Por este motivo, conseguir que el sistema nos calcule las ventas del día a día dejó de ser una simple propuesta interesante en papel; hoy por hoy es una necesidad operativa obligatoria y muy práctica si genuinamente buscamos darle un rumbo estructurado a toda la estrategia comercial de la tienda. El presente estudio se alineará con el Objetivo de Desarrollo Sostenible 9, Industria, innovación e infraestructura, específicamente con la meta 9.5, al desarrollar y evaluar un modelo de machine learning que fortalecerá las capacidades tecnológicas para la gestión de la demanda en un minimarket.

De manera complementaria, se vinculará con la meta 8.2 del Objetivo de Desarrollo Sostenible 8, al promover la productividad mediante una planificación de compras basada en datos, y con la meta 12.2 del Objetivo de Desarrollo Sostenible 12, al favorecer el uso eficiente de los recursos y la reducción del desperdicio asociado al exceso de productos perecibles.

A partir de esta realidad, se formuló el siguiente problema general de investigación: ¿De qué manera un modelo de machine learning permitirá predecir la demanda diaria por categoría de producto en un minimarket de Comas 2026? Los problemas específicos planteados fueron los siguientes: (P1) ¿cómo se recopilarán y depurarán los datos históricos de ventas e inventario del minimarket para la construcción del modelo predictivo?; (P2) ¿qué modelos predictivos de machine learning orientados a series temporales presentarán un mejor desempeño durante el entrenamiento para la demanda diaria por categoría?; (P3) ¿cuál será el nivel de desempeño de los modelos evaluados según las métricas de error MAE, RMSE y MAPE?; y (P4) ¿de qué manera el modelo seleccionado apoyará la planificación del inventario y la toma de decisiones ?

La investigación se justifica desde el punto de vista teórico porque integra conocimientos sobre machine learning, series temporales y predicción de demanda en el contexto de un minimarket. Asimismo, se justifica desde el punto de vista tecnológico porque demuestra la viabilidad de aplicar técnicas predictivas a un problema real de gestión comercial en un pequeño negocio. Desde el punto de vista práctico, la investigación ofrece una herramienta de apoyo para mejorar la planificación de la demanda; al predecir la demanda diaria por categoría, permite decidir qué productos comprar, qué categorías reforzar y cómo reducir los riesgos de desabastecimiento o exceso de mercadería.

Desde el punto de vista metodológico, la investigación propone un procedimiento de recopilación, preparación, entrenamiento y evaluación de datos que sirve como referencia para estudios similares. Finalmente, se justifica desde el punto de vista social y económico porque una gestión más eficiente de los productos mejora su disponibilidad para los clientes y reduce las pérdidas ocasionadas por una planificación inadecuada.

El objetivo general de la investigación fue desarrollar y evaluar un modelo de machine learning para predecir la demanda diaria por categoría de producto en un minimarket de Comas 2026. Para alcanzar este propósito, se plantearon los siguientes objetivos específicos: (OE1) recopilar y depurar los datos históricos de ventas e inventario del minimarket para la construcción del modelo predictivo; (OE2) entrenar y comparar el desempeño de diversos algoritmos de machine learning orientados a series temporales para la predicción de la demanda diaria por categoría; (OE3) evaluar el desempeño predictivo de los modelos entrenados utilizando las métricas de error

MAE, RMSE y MAPE; y (OE4) analizar la contribución predictiva del modelo seleccionado en la planificación del inventario y la toma de decisiones comerciales.

En cuanto a la hipótesis general, se planteó que el desarrollo de un modelo de machine learning permitirá predecir la demanda diaria por categoría de producto en un minimarket de Comas, 2026, logrando un desempeño predictivo, medido a través de MAE, RMSE y MAPE, que será significativamente mejor en comparación con un método de pronóstico base.

Las hipótesis específicas fueron las siguientes: (HE1) Los datos históricos de ventas e inventario, una vez depurados y organizados, permitirán identificar patrones de comportamiento de la demanda por categoría de producto. (HE2) Al menos uno de los modelos de machine learning evaluados presentará un error de predicción menor al método base durante el entrenamiento para la demanda diaria. (HE3) El nivel de error de predicción medido por MAE, RMSE y MAPE de los modelos seleccionados será significativamente menor que el método de pronóstico base. (HE4) La implementación del modelo 15 seleccionado permitirá optimizar la planificación del inventario al reducir los quiebres de stock y el exceso de inventario en el minimarket.

II. Metodología

La investigación fue de tipo aplicada, porque se orientó al desarrollo y la evaluación de una solución tecnológica para atender un problema concreto del Minimarket Taully, ubicado en Comas, durante el año 2026. El problema identificado fue la dificultad para predecir la demanda diaria por categoría de producto y disponer de información para planificar las compras y la reposición del inventario. En ese sentido, el estudio utilizó un modelo de machine learning para analizar registros históricos de ventas y generar pronósticos destinados a apoyar la toma de decisiones comerciales. Esta aplicación tecnológica tuvo como antecedente el trabajo de Mohd Shahar et al. [28], quienes utilizaron registros históricos de ventas de Rossmann y el algoritmo XGBoost para desarrollar y evaluar un modelo de pronóstico de ventas.

El alcance de la investigación fue descriptivo, con un propósito predictivo, debido a que se analizaron los patrones de demanda correspondientes a cada categoría de producto y se evaluó la capacidad de los modelos para estimar valores futuros a partir de dichos patrones. Para el estudio se consideraron dos variables. La variable independiente correspondió al modelo de machine learning, definido como un conjunto de algoritmos computacionales capaces de aprender patrones a partir de datos históricos y utilizarlos para generar predicciones [1], [4]. La variable dependiente fue la demanda diaria por categoría de producto, entendida como la cantidad de unidades demandadas o vendidas en cada categoría comercial durante un día determinado, sujeta a variaciones de volumen, disponibilidad y estacionalidad [1], [3].

Desde el punto de vista operacional, el modelo de machine learning comprendió la preparación de los registros, la generación de variables temporales, el entrenamiento de los algoritmos y la validación cronológica de las predicciones obtenidas. La demanda diaria por categoría se determinó mediante la consolidación de las ventas y los movimientos de inventario según la fecha y la categoría de producto. Para su análisis se consideraron las dimensiones de volumen de demanda, disponibilidad de inventario, patrón de demanda y precisión del pronóstico. La definición conceptual y operacional de las variables, así como sus dimensiones, indicadores y escalas de medición, se presentan en la tabla de operacionalización incluida en el Anexo 1.

La unidad de análisis estuvo constituida por el registro diario consolidado de ventas correspondiente a cada categoría de producto. La población estuvo conformada por la totalidad de los registros de ventas y movimientos de inventario almacenados en el sistema del Minimarket Taully, ubicado en Comas, correspondientes al periodo comprendido entre abril y diciembre de 2026. El estudio comprendió cinco categorías comerciales: abarrotes, bebidas, golosinas, helados y limpieza. Los registros de ventas se organizaron y consolidaron por fecha y categoría para analizar la demanda diaria.

La muestra estuvo conformada por la totalidad de los registros que cumplieron con los criterios establecidos después del proceso de depuración; por esta razón, se empleó un muestreo censal y no fue necesario aplicar una fórmula para determinar el tamaño muestral. Se consideraron las transacciones correspondientes al periodo de estudio que contaban con una fecha válida, una categoría correctamente identificada, un código de producto consistente y valores positivos en la salida de inventario.

Se excluyeron los registros duplicados, las operaciones anuladas, las devoluciones, los valores nulos, la información incompleta y los errores de digitación. Las campañas promocionales y los feriados se mantuvieron cuando se encontraban correctamente registrados, debido a que constituían información relevante para explicar las variaciones de la demanda. Solo se corrigieron o eliminaron aquellos valores atípicos que pudieron atribuirse a errores de registro. Como técnica de recolección de datos se utilizó el análisis documental cuantitativo.

Se revisaron los reportes históricos de ventas, los movimientos de almacén y los registros de inventario con el propósito de extraer, organizar y depurar la información requerida para el desarrollo del estudio. Se emplearon una ficha de registro de datos cuantitativos de ventas, una matriz de datos estructurada y una ficha de evaluación del modelo predictivo. Los instrumentos, sus campos y sus fórmulas de cálculo se incorporaron en el Anexo 2. Las fichas fueron elaboradas para este estudio y no correspondieron a instrumentos estandarizados con autores originales. Por esta razón, su validez de contenido requirió juicio de expertos con experiencia en metodología de investigación, análisis de datos o machine learning.

Se incorporaron las fichas técnicas de los instrumentos en el Anexo 3 y los formatos de validación para tres jueces expertos en los Anexos 4, 5 y 6. Dichos formatos debían consignar la valoración, las observaciones, la identificación y la firma de cada juez antes de la presentación de la versión final. La evaluación de la consistencia interna no fue aplicable, debido a que en el estudio no se emplearon cuestionarios ni escalas psicométricas. La calidad de los datos se garantizó mediante la revisión de registros duplicados, valores nulos, códigos, fechas, categorías y la correspondencia entre la información de ventas e inventario. Asimismo, se siguió un procedimiento definido para limpiar, transformar, entrenar y evaluar los datos, de manera que el proceso pudiera repetirse bajo las mismas condiciones.

El volumen de demanda se analizó mediante la cantidad demandada y el índice de salida de inventario. Para las fichas de inventario, la cantidad demandada se calculó mediante la expresión CD = (SI + EN) − SF, donde SI corresponde al stock inicial, EN a las entradas registradas y SF al stock final. La interpretación de este balance como cantidad vendida requiere verificar los ajustes, las

devoluciones, las mermas y otros movimientos de inventario. El índice de salida de inventario se calculó mediante ISI = CD / (SI + EN) y se expresó como porcentaje para representar la proporción de existencias disponibles que salió durante el periodo evaluado.
Por otro lado, la disponibilidad del inventario se evaluó mediante la tasa de quiebre de stock, calculada como TQS = (DQS / DD) × 100. Para cada categoría, DQS representa el número de días con quiebre de stock y DD los 30 días evaluados. El cálculo global consideró cinco categorías durante 30 días, equivalentes a 150 observaciones de categoría por día. Por tanto, se dividió la suma de los días con quiebre de las cinco categorías entre 150 y se multiplicó el resultado por 100. Este total no representa 150 categorías ni 150 días calendario. Asimismo, el comportamiento de la demanda se analizó mediante el índice estacional, calculado como IE = VD / VPRD. En esta fórmula, VD corresponde a la venta diaria y VPRD a la venta promedio diaria del mes de referencia. Los valores superiores a uno indican ventas diarias por encima de dicha referencia, mientras que los inferiores a uno indican ventas por debajo de ella.

Estos indicadores permitieron identificar variaciones recurrentes en la demanda y reconocer las categorías con mayor riesgo de desabastecimiento. El análisis de los datos se realizó siguiendo el orden cronológico de los registros. Para ello, la información se organizó por fecha y categoría de producto, y se incorporaron variables temporales como el día de la semana, los feriados y las promociones registradas. Asimismo, se evitaron particiones aleatorias que pudieran alterar la secuencia de las series temporales. Los registros más antiguos se utilizaron para el entrenamiento del modelo, mientras que los periodos posteriores se reservaron para las etapas de validación y prueba. Finalmente, la capacidad de generalización se evaluó mediante validación hacia adelante, respetando en todo momento el orden temporal de los datos.

En una primera etapa se realizó un análisis descriptivo de la demanda, considerando frecuencias, totales, promedios y variaciones según la fecha y la categoría de producto. Luego, se comparó el desempeño del promedio móvil simple, utilizado como modelo base, con ARIMA, Random Forest, CatBoost y XGBoost. El análisis se centró en la capacidad predictiva de cada modelo, sin buscar establecer relaciones causales ni asociaciones entre variables. Para evaluar su desempeño se utilizaron las métricas MAE, RMSE y MAPE. El MAE permitió conocer el error absoluto promedio, el RMSE dio mayor peso a los errores de mayor magnitud y el MAPE mostró el error de predicción en términos porcentuales [31].

El MAPE se calculó solo cuando la demanda real fue distinta de cero. Para los registros con demanda igual a cero se utilizaron las métricas MAE y RMSE, con el fin de evitar divisiones indefinidas. Se seleccionó el modelo que presentó el menor error frente a la línea base, considerando tanto las métricas obtenidas como la estabilidad de los resultados en las validaciones temporales. Asimismo,

la investigación se desarrolló bajo los principios de integridad científica, objetividad, transparencia, trazabilidad y confidencialidad. Los registros históricos de ventas e inventario fueron utilizados exclusivamente con fines académicos.

El acceso a la información estuvo limitado al investigador y los resultados se presentaron de manera agregada, evitando la exposición de datos comerciales sensibles o identificadores personales. Debido a que no se recopilaron datos directamente de personas ni se aplicaron instrumentos a participantes, no fue necesario utilizar consentimiento informado ni asentimiento. La autorización institucional para el uso de la información del Minimarket Taully se incorporó en los Anexos 7 y 8. En caso de que los registros incluyeran datos personales, estos debían ser anonimizados antes de iniciar el análisis. Asimismo, las autorizaciones institucionales, las fichas de validación firmadas y cualquier documento que pudiera revelar información comercial sensible permanecieron bajo custodia del investigador.

Aunque estos documentos fueron mencionados en el informe e incluidos como sustento para la evaluación académica, se estableció que no debían ser publicados en el Repositorio Institucional, debido a que contienen información de carácter sensible y de uso restringido.

III. Resultados

IV. Discusión

V. Conclusiones

VI. Recomendaciones

Referencias

[1] C. Brackmann, T. Friedrich, y N. Urbach, "Identifying Application Areas for Machine Learning in the Retail Industry", SN Computer Science, 2023. Consultado: 1 jun. 2026. [En línea]. Disponible: https://link.springer.com/article/10.1007/s42979-023-01888-w

[2] J. Wang y L. Luo, "A forecasting method of multi-category product sales: analysis and application", Journal of Cloud Computing, 2023. Consultado: 1 jun. 2026. [En línea]. Disponible: https://link.springer.com/article/10.1007/s44176-023-00012-9

[3] C. Auppakorn y C. Phumchusri, "Daily Sales Forecasting for Variable-Priced Items in Retail Business", ACM International Conference Proceeding Series, 2022. Consultado: 1 jun. 2026. [En línea]. Disponible: https://dl.acm.org/doi/10.1145/3535782.3535794

[4] Y. Ahmadov, B. Minaei-Bidgoli, y A. Harati, "Deep learning-based approach for forecasting intermittent online sales", Discover Artificial Intelligence, 2023. Consultado: 1 jun. 2026. [En línea]. Disponible: https://link.springer.com/article/10.1007/s44163-023-00085-1

[5] H. Chan y M. I. M. Wahab, "A machine learning framework for predicting weather impact on retail sales", Supply Chain Analytics, 2024. Consultado: 1 jun. 2026. [En línea]. Disponible: https://www.sciencedirect.com/science/article/pii/S2949863524000013

[6] S. Chen, J. Zhang, y X. Wang, "Which product description phrases affect sales forecasting? An explainable AI framework", Decision Support Systems, 2024. Consultado: 1 jun. 2026. [En línea]. Disponible: https://www.sciencedirect.com/science/article/abs/pii/S0167923623001409

[7] Universidad Tecnológica del Perú, "Predicción de la demanda de productos con Machine Learning en un minimarket", Tesis, Univ. Tecnológica del Perú, 2024. Consultado: 1 jun. 2026. [En línea]. Disponible: https://repositorio.utp.edu.pe/item/0af5cc5f-1b49-43e1-b3b1-af734f5202fa

[8] J. M. Palomino Huarilloclla, "Implementación de un modelo de machine learning para la predicción de la demanda de una ferretería en Moquegua, 2024", Tesis, Univ. César Vallejo, Perú, 2024. Consultado: 1 jun. 2026. [En línea]. Disponible: https://alicia.concytec.gob.pe/vufind/Record/UCVV_74ad36992d479d9df5029d521249d464/Details

[9] R. C. Montero López, "Sistema web inteligente basado en machine learning para apoyar la gestión de inventarios en la empresa E.B. Pareja Lecaros S.A.", Tesis, Univ. Católica Santo Toribio de Mogrovejo, Perú, 2024. Consultado: 1 jun. 2026. [En línea]. Disponible: https://repositorio.usat.edu.pe/items/10c2c805-827f-4e41-bc96-a4df605c5dce

[10] G. M. Ponce Illacutipa, "Modelo basado en Machine Learning para optimizar el pronóstico de ventas de la empresa Ricos Pan, año 2020–2021", Tesis, Perú, 2021. Consultado: 1 jun. 2026. [En línea]. Disponible: https://alicia.concytec.gob.pe/vufind/Record/RNAP_5b1ee92720df311aa5a22708a1fb1488

[11] G. A. Flores Taquiri y J. S. Montalvo Celis, "Machine learning para la predicción en la gestión de inventario dirigida a PYMES de venta de productos tecnológicos", Tesis, Univ. César Vallejo, Perú, 2024. Consultado: 1 jun. 2026. [En línea]. Disponible: https://alicia.concytec.gob.pe/vufind/Record/UCVV_802cf5f75bd0c420ae4084d6b71ddb29

[12] R. L. León Villavicencios y F. E. Vinces Chumbes, "Machine Learning para la gestión de ventas en la empresa Forever Group SAC", Tesis, Univ. César Vallejo, Perú, 2024. Consultado: 1 jun. 2026. [En línea]. Disponible: https://alicia.concytec.gob.pe/vufind/Record/UCVV_0121b72d7f74603bbdd31f79cd25f4ad

[13] P. A. Anchante Aybar y D. D. Fernández Chávez, "Machine Learning para la toma de decisiones en la gestión de ventas, Lima 2024", Tesis, Univ. César Vallejo, Perú, 2024. Consultado: 1 jun. 2026. [En línea]. Disponible: https://alicia.concytec.gob.pe/vufind/Record/UCVV_8cda3aace716d90c01edbb0c689177c8/Details

[14] J. A. Rojas Vilca, "Aplicativo Móvil con Machine Learning para la gestión de ventas en productos de la empresa Optilook de Lima, 2024", Tesis, Univ. César Vallejo, Perú, 2024. Consultado: 1 jun. 2026. [En línea]. Disponible:

https://alicia.concytec.gob.pe/vufind/Record/UCVV_d500babbd2fb53a1abf122d8d98c2f3f/Details

[15] K. E. Serna Berrocal, "Modelo machine learning para predecir las ventas de una empresa RETAIL, 2025", Tesis, Perú, 2025. Consultado: 1 jun. 2026. [En línea]. Disponible: https://alicia.concytec.gob.pe/vufind/Record/UNSJ_a2810f55353e34c2f024e89d83330f26/Details

[16] B. P. González Jauregui y D. M. Mariscal Cruzado, "Improvement Proposal Based on Machine Learning, Big Data and DDMRP to Improve Forecasting Compliance in a Consumer Goods Company", Tesis, Univ. de Lima, Perú, 2024. Consultado: 1 jun. 2026. [En línea]. Disponible: https://repositorio.ulima.edu.pe/bitstream/handle/20.500.12724/21467/T018_71910212_T.pdf?isAllowed=y&sequence=1

[17] G. Padmanabham, "Machine Learning Framework for Retail Sales Forecasting", International Journal of Computational and Experimental Science and Engineering, 2025. Consultado: 1 jun. 2026. [En línea]. Disponible: https://www.researchgate.net/publication/396173583_Machine_Learning_Framework_for_Retail_Sales_Forecasting

[18] O. O. Mustapha y T. Sithole, "Forecasting Retail Sales using Machine Learning Models", American Journal of Statistics and Actuarial Sciences, 2025. Consultado: 1 jun. 2026. [En línea]. Disponible: https://www.researchgate.net/publication/390949992_Forecasting_Retail_Sales_using_Machine_Learning_Models

[19] S. Mansur, F. Ahmed, e M. R. Islam, "Sales forecasting for retail stores using hybrid neural networks and machine learning", PeerJ Computer Science, 2025. Consultado: 1 jun. 2026. [En línea]. Disponible: https://pmc.ncbi.nlm.nih.gov/articles/PMC12453866

[20] R. S. Ahmed, M. A. Khan, y S. Ali, "Comparison of Deep Learning Algorithms for Retail Sales Forecasting", ICCK Transactions on Intelligent Systematics, 2024. Consultado: 1 jun. 2026. [En línea]. Disponible: https://www.icck.org/article/abs/tis.2024.300700

[21] Y. Liu, D. Kalaitzi, M. Wang, y C. Papanagnou, "A machine learning approach to inventory stockout prediction", Journal of Digital Economy, 2025. Consultado: 1 jun. 2026. [En línea]. Disponible: https://www.sciencedirect.com/science/article/pii/S2773067025000202

[22] M. S. Sousa, A. M. Moreira, y J. Ferreira, "Predicting demand for new products in fashion retailing using machine learning", Expert Systems with Applications, 2025. Consultado: 1 jun. 2026. [En línea]. Disponible: https://www.sciencedirect.com/science/article/pii/S0957417424021808

[23] C. C. Wang, Y. H. Chen, y T. Y. Lin, "Dynamic Dual-Phase Forecasting Model for New Product Demand", Mathematics, 2025. Consultado: 1 jun. 2026. [En línea]. Disponible: https://www.mdpi.com/2227-7390/13/10/1613

[24] S. Hwang, J. Kim, y M. Park, "Sales Forecasting for New Products Using Homogeneity-Based Clustering and Ensemble Learning", Electronics, 2025. Consultado: 1 jun. 2026. [En línea]. Disponible: https://www.mdpi.com/2079-9292/14/3/520

[25] H. Hu, D. Tan, P. Thaichon, B. Wang, y Z. Zhu, "Grid-based market sales forecasting for retail businesses using automated machine learning and geospatial intelligence", Expert Systems with Applications, 2025. Consultado: 1 jun. 2026. [En línea]. Disponible: https://www.sciencedirect.com/science/article/abs/pii/S0957417425014915

[26] M. A. Shahzad, M. A. Khan, y S. Ullah, "Demand forecasting for retail using three-S temporal fusion transformer", Supply Chain Analytics, 2025. Consultado: 1 jun. 2026. [En línea]. Disponible: https://www.sciencedirect.com/science/article/abs/pii/S3051064325000305

[27] A. Seyam, M. R. Islam, y S. Hossain, "The application of machine learning and deep learning on demand forecasting", International Journal of Information Management Data Insights, 2026. Consultado: 1 jun. 2026. [En línea]. Disponible: https://www.sciencedirect.com/science/article/pii/S1474034626003174

[28] N. A. Mohd Shahar, N. H. Abd Rahman, y S. S. Maidin, "Sales Forecasting Using Machine Learning Methods for Retail Store", Atlantis Press, 2024. Consultado: 1 jun. 2026. [En línea]. Disponible: https://www.atlantis-press.com/proceedings/invent-24/126005569

[29] C. I. C. Obi, "Demand Forecasting in Retail Business Using the Ensemble Machine Learning Framework: A Stacking Approach", American Scientific Research Journal for Engineering, Technology, and Sciences, 2024. Consultado: 1 jun. 2026. [En línea]. Disponible: https://asrjetsjournal.org/American_Scientific_Journal/article/view/11010

[30] I. P. Mariñ, "A Demand Forecasting Model Leveraging Machine Learning", Scientific Programming, 2024. Consultado: 1 jun. 2026. [En línea]. Disponible: https://onlinelibrary.wiley.com/doi/10.1155/2024/8425058

[31] R. J. Hyndman y G. Athanasopoulos, Forecasting: Principles and Practice, 3.ª ed. OTexts, 2021. [En línea]. Disponible: https://otexts.com/fpp3/

Anexos

Anexo 1. Tabla de operacionalización de variables.

Variables	Definición conceptual	Definición operacional	Dimensiones	Indicadores	Escala de Mediciones
Modelo de machine learning	Algoritmos computacionales que aprenden patrones de datos históricos para realizar predicciones [1], [4].	Proceso de entrenamiento y ajuste de algoritmos de machine learning (ej. XGBoost, Redes Neuronales) utilizando features temporales.			

Demanda diaria por categoría de producto	Cantidad de productos vendidos por categoría, influenciada por factores estacionales y externos [1], [3].	Registro numérico consolidado de las ventas diarias por categoría de producto, depurado de los sistemas del minimarket.	Volumen de demanda	Cantidad de demanda (Unidad)	Razón
				Índice de Salida de Inventario	
				Tasa de Quiebre de Stock	
			Patrón de Demanda	Estacionalidad	Razón
			Precisión del Pronóstico	Error de Pronóstico	Razón

Anexo 2. Instrumentos de recolección de datos.

Instrumento de recolección de datos del indicador para el Pretest: Cantidad demandada

INDICADOR:	Cantidad Demandada
INVESTIGADOR:	Guerrero Mora, Carlos David Elian
LUGAR DE ESTUDIO:	Minimarket Taully, Comas
FÓRMULA:	CD = (SI + EN) - SF
DONDE:	CD = Cantidad Demandada SI = Stock Inicial EN = Entradas SF = Stock Final
Momento	Pretest

N°	Categoria	SI	EN	SF	CD
1	Abarrotes	394	881	315	960
2	Bebidas	712	1 481	597	1 596
3	Golosinas	645	905	413	1 137
4	Helados	191	309	151	349
5	Limpieza	172	335	102	405
	Total	2 114	3 911	1 578	4 447

Instrumento de recolección de datos del indicador para el Postest: Cantidad demandada

INDICADOR:	Cantidad Demandada
INVESTIGADOR:	Guerrero Mora, Carlos David Elian
LUGAR DE ESTUDIO:	Minimarket Taully, Comas
FÓRMULA:	CD = (SI + EN) - SF
DONDE:	CD = Cantidad Demandada SI = Stock Inicial EN = Entradas SF = Stock Final
Momento	Postest

N°	Categoria	SI	EN	SF	CD
1	**Abarrotes**	**372**	**949**	**290**	**1 031**
2	**Bebidas**	**738**	**1 433**	**559**	**1 612**
3	**Golosinas**	**638**	**984**	**448**	**1 174**
4	**Helados**	**210**	**365**	**141**	**434**
5	**Limpieza**	**169**	**227**	**107**	**289**
	Total	**2 127**	**3 958**	**1 545**	**4 540**

Instrumento de recolección de datos del indicador para el Pretest: Índice de Salida de Inventario

INDICADOR:	Índice de Salida de Inventario
INVESTIGADOR:	Guerrero Mora, Carlos David Elian
LUGAR DE ESTUDIO:	Minimarket Taully, Comas
FÓRMULA:	ISI = CD / (SI + EN)
DONDE:	ISI = Índice de Salida de Inventario CD = Cantidad Demandada SI = Stock Inicial EN = Entradas
Momento	Pretest

N°	Categoría	(CD)	Stock Inicial (SI)	Entradas (EN)	Índice de Salida de Inventario (ISI)
1	**Abarrotes**	**960**	**394**	**881**	**75,29 %**
2	**Bebidas**	**1 596**	**712**	**1 481**	**72,78 %**
3	**Golosinas**	**1 137**	**645**	**905**	**73,35 %**
4	**Helados**	**349**	**191**	**309**	**69,80 %**
5	**Limpieza**	**405**	**172**	**335**	**79,88 %**
	Total	**4 447**	**2 114**	**3 911**	**73,81 %**

Instrumento de recolección de datos del indicador para el Postest: Índice de Salida de Inventario

INDICADOR:	Índice de Salida de Inventario
INVESTIGADOR:	Guerrero Mora, Carlos David Elian
LUGAR DE ESTUDIO:	Minimarket Taully, Comas
FÓRMULA:	ISI = CD / (SI + EN)
DONDE:	ISI = Índice de Salida de Inventario CD = Cantidad Demandada SI = Stock Inicial EN = Entradas
Momento	Postest

N°	Categoria	(CD)	Stock Inicial (SI)	Entradas (EN)	Índice de Salida de Inventario (ISI)
1	**Abarrotes**	**1 031**	**372**	**949**	**78,05 %**
2	**Bebidas**	**1 612**	**738**	**1 433**	**74,25 %**
3	**Golosinas**	**1 174**	**638**	**984**	**72,38 %**
4	**Helados**	**434**	**210**	**365**	**75,48 %**
5	**Limpieza**	**289**	**169**	**227**	**72,98 %**
	Total	**4 540**	**2 127**	**3 958**	**74,61 %**

Instrumento de recolección de datos del indicador para el Pretest: Tasa de quiebre de stock

INDICADOR:	Tasa de Quiebre de Stock
INVESTIGADOR:	Guerrero Mora, Carlos David Elian
LUGAR DE ESTUDIO:	Minimarket Taully, Comas
FÓRMULA:	$\mathrm{TQS} = (\mathrm{DQS} / \mathrm{DD}) \times 100$
DONDE:	TQS = Tasa de Quiebre de Stock DQS = Días con Quiebre de Stock DD = Días Evaluados
Momento	Pretest

N°	Categoria	DQS	DD	TQS
1	Abarrotes	1	30	3,33 %
2	Bebidas	10	30	33,33 %
3	Golosinas	11	30	36,67 %
4	Helados	1	30	3,33 %
5	Limpieza	0	30	0,00 %
	Total	23	150	15,33 %

Instrumento de recolección de datos del indicador para el Postest: Tasa de quiebre de stock

INDICADOR:	Tasa de Quiebre de Stock
INVESTIGADOR:	Guerrero Mora, Carlos David Elian
LUGAR DE ESTUDIO:	Minimarket Taully, Comas
FÓRMULA:	$\mathrm{TQS} = (\mathrm{DQS} / \mathrm{DD}) \times 100$
DONDE:	TQS = Tasa de Quiebre de Stock DQS = Días con Quiebre de Stock DD = Días Evaluados
Momento	Postest

N°	Categoria	DQS	DD	TQS
1	**Abarrotes**	**1**	**30**	**3,33 %**
2	**Bebidas**	**2**	**30**	**6,67 %**
3	**Golosinas**	**7**	**30**	**23,33 %**
4	**Helados**	**3**	**30**	**10,00 %**
5	**Limpieza**	**0**	**30**	**0,00 %**
	Total	**13**	**150**	**8,67 %**

Instrumento de recolección de datos del indicador para el Pretest: Estacionalidad

INDICADOR:	Estacionalidad
INVESTIGADOR:	Guerrero Mora, Carlos David Elian
LUGAR DE ESTUDIO:	Minimarket Taully, Comas
FÓRMULA:	$IE = VD / VPRD$
DONDE:	IE = Índice Estacional VD = Venta Diaria VPRD = Venta promedio diaria del mes de referencia
Momento	Pretest

N°	IE	VD	VPRD
1	1,10	287	261,40
2	0,93	243	261,40
3	0,84	220	261,40
4	1,07	281	261,40
5	0,86	226	261,40
6	0,77	202	261,40
7	0,92	241	261,40
8	1,06	278	261,40
9	1,15	301	261,40
10	0,92	240	261,40
11	0,93	242	261,40
12	0,85	221	261,40
13	1,03	270	261,40
14	1,12	293	261,40
15	1,22	318	261,40
16	1,18	309	261,40
17	1,03	269	261,40
18	0,85	221	261,40
19	0,83	216	261,40
20	1,22	318	261,40
21	1,03	269	261,40
22	1,22	318	261,40
23	1,18	308	261,40
24	0,94	247	261,40
25	0,84	220	261,40
26	1,02	267	261,40
27	0,92	241	261,40
28	1,07	281	261,40
29	1,15	301	261,40
30	1,03	268	261,40

Instrumento de recolección de datos del indicador para el Postest: Estacionalidad

INDICADOR:	Estacionalidad
INVESTIGADOR:	Guerrero Mora, Carlos David Elian
LUGAR DE ESTUDIO:	Minimarket Taully, Comas
FÓRMULA:	$IE = VD / VPRD$
DONDE:	IE = Índice Estacional VD = Venta Diaria VPRD = Venta promedio diaria del mes de referencia
Momento	Postest

N°	IE	VD	VPRD
1	0,96	250	261,40
2	1,04	272	261,40
3	0,71	185	261,40
4	0,96	250	261,40
5	1,23	322	261,40
6	1,25	326	261,40
7	1,04	272	261,40
8	0,80	209	261,40
9	1,07	281	261,40
10	1,04	271	261,40
11	1,09	284	261,40
12	1,19	312	261,40
13	1,28	334	261,40
14	1,22	319	261,40
15	0,96	251	261,40
16	0,99	258	261,40
17	0,76	198	261,40
18	0,93	244	261,40
19	1,19	311	261,40
20	1,12	292	261,40
21	1,09	284	261,40
22	0,85	222	261,40
23	0,89	233	261,40
24	0,77	200	261,40
25	0,78	205	261,40
26	0,96	250	261,40
27	0,98	257	261,40
28	0,96	252	261,40
29	0,96	252	261,40
30	0,98	255	261,40

Instrumento de recolección de datos del indicador para el Pretest: Error de pronóstico

INDICADOR:	Error de Pronóstico
INVESTIGADOR:	Guerrero Mora, Carlos David Elian
LUGAR DE ESTUDIO:	Minimarket Taully, Comas
FÓRMULA:	MAPE = (100/n) × Σ |(Demanda Real − Demanda Pronosticada) / Demanda Real|
DONDE:	MAPE = Error Porcentual Absoluto Medio DR = Demanda Real DP = Demanda Pronosticada n = Número de observaciones
Momento:	Pretest

N°	Categoría	Demanda Real (DR)	Demanda Pronosticada (DP)	MAPE
1	**Abarrotes**	**1 604**	**1 636,18**	**21,20 %**
2	**Bebidas**	**2 799**	**2 598,75**	**12,62 %**
3	**Golosinas**	**2 218**	**2 204,68**	**20,50 %**
4	**Helados**	**715**	**795,25**	**39,85 %**
5	**Limpieza**	**580**	**532,29**	**24,61 %**
	Total	**7 916**	**7 767,14**	**23,76 %**

Instrumento de recolección de datos del indicador para el Postest: Error de pronóstico

INDICADOR:	Error de Pronóstico
INVESTIGADOR:	Guerrero Mora, Carlos David Elian
LUGAR DE ESTUDIO:	Minimarket Taully, Comas
FÓRMULA:	MAPE = (100/n) × Σ |(Demanda Real − Demanda Pronosticada) / Demanda Real|
DONDE:	MAPE = Error Porcentual Absoluto Medio DR = Demanda Real DP = Demanda Pronosticada n = Número de observaciones
Momento:	Postest

N°	Categoria	Demanda Real (DR)	Demanda Pronosticada (DP)	MAPE
1	**Abarrotes**	**1 653**	**1 506,70**	**21,19 %**
2	**Bebidas**	**2 810**	**2 666,39**	**15,08 %**
3	**Golosinas**	**2 129**	**2 226,85**	**22,53 %**
4	**Helados**	**792**	**708,73**	**31,42 %**
5	**Limpieza**	**467**	**575,62**	**40,81 %**
	Total	**7 851**	**7 684,29**	**26,21 %**

TAULLY MARKET E.I.R.L
JAIMES MAYS MIGUEL ANGEL
GERENTE GENERAL

Anexo 7. Solicitud de autorización para realizar la investigación de la empresa.

Universidad César Vallejo	PROTOCOLO PARA LA REVISIÓN DE LOS PROYECTOS DE INVESTIGACIÓN POR LOS COMITÉS DE ÉTICA EN INVESTIGACIÓN	Código : PP-PT-02.02 Versión : 00 Fecha : 17-06-2025 Página : 1 de 1

Solicitud de autorización para realizar investigación en una institución

Lima, 01 de junio de 2026

Señor (a):
Jaimes Mays Miguel Ángel
Gerente General
TAULLY MARKET E.I.R.L.

Presente.-

Es grato dirigirme a usted para saludarlo y, a la vez, manifestarle que dentro de mi formación académica como estudiante investigador, se contempla la realización de una investigación con fines netamente académicos para la obtención de mi título profesional de Ingeniero de Sistemas.

En tal sentido, considerando la relevancia de su organización, solicito su colaboración para poder realizar mi investigación en su representada y obtener la información necesaria para desarrollar la investigación titulada "Modelo de machine learning para predecir la demanda diaria por categoría de producto en Minimarket Taully, Comas, 2026". En dicha investigación me comprometo a utilizar la información únicamente con fines académicos, respetando la confidencialidad de los datos proporcionados.

Se adjunta la carta de autorización de uso de información en caso de que se considere la aceptación de esta solicitud para ser llenada por el representante de la empresa.

Agradeciéndole anticipadamente por vuestro apoyo en favor de mi formación profesional, hago propicia la oportunidad para expresar las muestras de mi especial consideración.

Atentamente.

Nombres y apellidos del(los) investigador(es)	DNI N.°	Firma
Carlos David Elian Guerrero Mora	71926970	

NOTA: *Cualquier documento impreso diferente del original y cualquier archivo electrónico que se encuentren fuera del campus virtual Trilce serán considerados como COPIA NO CONTROLADA.*

Anexo 8. Autorización de uso de información de la empresa.

Universidad César Vallejo	PROTOCOLO PARA LA REVISIÓN DE LOS PROYECTOS DE INVESTIGACIÓN POR LOS COMITÉS DE ÉTICA EN INVESTIGACIÓN	Código : PP-PT-02.02 Versión : 00 Fecha : 17-06-2025 Página : 1 de 1

Autorización de uso de información de la institución

Lima, 01 de junio de 2026

Yo, Jaimes Mays Miguel Ángel, identificado con DNI N.° 40434815, en mi calidad de Gerente General de la empresa TAULLY MARKET E.I.R.L., con R.U.C. N.° 20610066748, ubicada en Av. Micaela Bastidas N.° 801, Retablo, Comas, Lima, permito el uso de información comercial relacionada con ventas e inventario para fines académicos.

OTORGO LA AUTORIZACIÓN,

Al señor Carlos David Elian Guerrero Mora, identificado con DNI N.° 71926970, del Programa de Estudios de Ingeniería de Sistemas de la Universidad César Vallejo, para que tenga acceso y emplee datos relacionados con registros de ventas, productos, categorías, cantidades vendidas, fechas de venta e información de inventario de la institución, con la finalidad de desarrollar su investigación titulada "Modelo de machine learning para predecir la demanda diaria por categoría de producto en Minimarket Taully, Comas, 2026".

Indicar si el representante que autoriza la información de la institución solicita mantener el nombre o cualquier distintivo de la empresa en reserva, marcando con una "X" la opción seleccionada.

( ) Mantener en reserva el nombre o cualquier distintivo de la empresa; o

(X) Mencionar el nombre de la empresa.

Nombres y apellidos del representante	DNI N.°	Firma
Jaimes Mays Miguel Ángel	40434815	TAULLY MARKET E.I.R.L. JAIMES MAYS MIGUEL ANGEL GERENTE GENERAL

El investigador declara que los datos emitidos en esta carta y en el informe de investigación son auténticos. En caso de comprobarse la falsedad de datos, el investigador será sometido al inicio del procedimiento disciplinario correspondiente y de acuerdo al Código de Ética en Investigación de nuestra Universidad; asimismo, asumirá toda la responsabilidad ante posibles acciones legales que la institución, otorgante de información, pueda ejecutar.

Nombres y apellidos del(los) investigador(es)	DNI N.°	Firma
Carlos David Elian Guerrero Mora	71926970	

NOTA: *Cualquier documento impreso diferente del original y cualquier archivo electrónico que se encuentren fuera del campus virtual Trilce serán considerados como COPIA NO CONTROLADA.*

Anexo 9

taully

DETALLAR LAS ACTIVIDADES	TIEMPO											
FASE / ACTIVIDAD	Mes 1				Mes 2				Mes 3			
SPRINT	Sprint 1		Sprint 2		Sprint 3		Sprint 4		Sprint 5		Sprint 6	
SEMANA	1	2	3	4	5	6	7	8	9	10	11	12
18. Sprint 5: reproducir postest y completar tablas del Anexo 2									X	X		
19. Sprint 6: validar kardex real, documentación y entrega											X	X
20. Integrar cambios, pruebas y documentación de cada incremento	X	X	X	X	X	X	X	X	X	X	X	X
FASE 4. MONITOREO Y CONTROL - SCRUM												
21. Daily Scrum y seguimiento del objetivo del Sprint	X	X	X	X	X	X	X	X	X	X	X	X
22. Actualizar tareas y evidencia en Sprint Backlog	X	X	X	X	X	X	X	X	X	X	X	X
23. Gestionar impedimentos, disponibilidad de datos y riesgos	X	X	X	X	X	X	X	X	X	X	X	X
24. Verificar criterios de aceptación y Definition of Done	X	X	X	X	X	X	X	X	X	X	X	X
25. Sprint Review con demostración del incremento		X		X		X		X		X		X
26. Registrar observaciones y validación de interesados		X		X		X		X		X		X
27. Refinar Product Backlog y prioridades del siguiente Sprint		X		X		X		X		X		X
28. Revisar tareas terminadas, defectos y métricas de pronóstico	X	X	X	X	X	X	X	X	X	X	X	X
29. Sprint Retrospective y acuerdos de mejora		X		X		X		X		X		X
30. Aplicar acciones de mejora del Sprint anterior			X	X	X	X	X	X	X	X	X	X
FASE 5. CIERRE (PMI)												
31. Validar producto y registrar pendientes críticos											X	X
32. Consolidar manual, cálculos, pruebas y evidencias											X	X
33. Transferir solución y solicitar aceptación formal												X
34. Documentar lecciones aprendidas y riesgos abiertos												X
35. Presentar resultados y obtener conformidad del plan												X

TAULLY MARKET E.I.R.L
JAIMES MAYS MIGUEL ANGEL
GERENTE GENERAL

Duración propuesta: 12 semanas. La empresa y el docente deberán aprobar las fechas, los responsables y el alcance antes de la ejecución. Datos de razón social y RUC tomados del documento previo proporcionado; pendiente corroboración administrativa. Contacto informado: Jaimes Mays Miguel Angel; no se presume su cargo ni representación legal.

I. Conformidad del Plan de Prácticas Preprofesionales

JEFE INMEDIATO:	
Jaimes Mays Miguel Ange *DNI : 40434815*	
	
Firma y Sello	TAULLY MARKET E.I.R.L. JAIMES MAYS MIGUEL ANGEL GERENTE GENERAL

taully

Anexo 1 Aplicación de Scrum al proyecto Taully

Objetivo general

Desarrollar, validar y documentar un sistema que estime la demanda diaria por categoría del Minimarket Taully a partir de reportes de ventas y permita contrastar sus resultados con datos históricos y exportaciones reproducibles.

Product Goal

Disponer de un sistema trazable de carga, clasificación, pronóstico y evaluación que el responsable del negocio pueda revisar con sus fuentes y utilizar como apoyo a la planificación, sin confundir estimaciones con ventas realizadas.

Alcance y situación inicial

El programa existente incluye interfaz Flask, catálogo maestro, consolidación de ventas, entrenamiento por categoría, pronóstico y evaluación retrospectiva con exportación Excel. El plan organiza su validación y las mejoras pendientes; no acredita que los seis Sprints ya se hayan ejecutado.

Quedan fuera la compra automática, la sustitución del POS y la afirmación de mejoras operativas no demostradas. La distribución del pronóstico a productos no equivale a un modelo entrenado directamente para cada SKU.

Responsabilidad	Asignación propuesta
Product Owner	Representante del negocio por designar. Prioriza necesidades y valida el valor de las entregas.
Scrum Master	Persona por designar. Facilita el trabajo Scrum y gestiona impedimentos.
Desarrollo	Guerrero Mora, Carlos David Elian, como practicante propuesto; equipo y disponibilidad por confirmar.
Revisión académica	Docente o coordinador por confirmar. Revisa coherencia metodológica y evidencias.

Se propone Sprint Planning al inicio, Daily Scrum de seguimiento, Sprint Review y Sprint Retrospective al cierre de cada Sprint. Se conservarán fecha, participantes, acuerdos y evidencias reales. No se consignan reuniones, firmas ni aprobaciones que no estén documentadas.

Definition of Done

Una historia se considera terminada cuando cumple sus criterios, sus cálculos se contrastan con la fuente, pasan las pruebas pertinentes, se identifican los datos demostrativos, se actualiza la documentación y el incremento queda disponible para la revisión. La aceptación se registra cuando ocurra.

TAULLY MARKET E.I.R.L
JAIMES MAYS MIGUEL ANGEL
GERENTE GENERAL

taully

Anexo 2 Product Backlog propuesto

Prioridades y Sprints son propuestos y deberán acordarse con el responsable. Cada historia describe una capacidad del producto y una comprobación observable.

ID y Sprint	Historia y prioridad	Criterio de aceptación
HU01 · S1	Como encargado, quiero cargar ventas y catálogo para clasificar productos. Alta.	Procesar reportes autorizados; comprobar categorías y productos sin correspondencia. Función existente a validar.
HU02 · S2	Como revisor, quiero un historial consistente para rastrear las ventas. Alta.	Contrastar fechas y totales contra reportes; revisar duplicados y registros sin categoría.
HU03 · S3	Como analista, quiero comparar modelos por categoría. Alta.	Verificar separación cronológica, variables y selección por WAPE; reportar exclusiones y métricas.
HU04 · S4	Como encargado, quiero pronósticos y exportaciones para planificar. Alta.	Comprobar horizonte, fecha base y totales por categoría; identificar asignación estimada a productos.
HU05 · S5	Como docente, quiero reproducir el postest. Alta.	Ejecutar corte 16/08/2026 y 30 días con la base revisada; contrastar 150 pares, DR 7851 y MAPE 26,21 %.
HU06 · S5	Como revisor, quiero visualizar las tablas del Anexo 2. Alta.	Implementar y exportar VP, VPR, IE y detalle diario con fuente y referencia explícitas. Actualmente pendientes en el panel.
HU07 · S6	Como encargado, quiero indicadores con kardex real. Alta.	Conciliar saldos, entradas y salidas; recalcular ISI y TQS y distinguirlos de la demostración actual.
HU08 · S6	Como usuario, quiero manual y entrega verificable. Media.	Entregar guía con capturas, evidencia de pruebas pertinentes y pendientes; solicitar conformidad real.

La estimación del esfuerzo se acordará durante la planificación. No se atribuyen puntos, velocidad histórica ni horas efectivamente trabajadas sin registro. Las seis ventanas de dos semanas son la propuesta del formato.

TAULLY MARKET E.I.R.L
JAIMES MAYS MIGUEL ANGEL
GERENTE GENERAL

taully

Anexo 3 Incrementos y control de evidencia

Sprint	Objetivo e incremento esperado
1 · Semanas 1 y 2	Alcance y datos: fuentes autorizadas, catálogo revisado, Product Backlog y criterios acordados.
2 · Semanas 3 y 4	Historial trazable: conciliación de ventas, fechas y categorías con registro de incidencias.
3 · Semanas 5 y 6	Entrenamiento verificable: validación cronológica y documentación del método elegido por categoría.
4 · Semanas 7 y 8	Pronóstico utilizable: revisión de horizontes, exportaciones y distribución estimada a productos.
5 · Semanas 9 y 10	Postest reproducible y tablas de demanda integradas: comparación de pantalla, Excel y fichas.
6 · Semanas 11 y 12	Validación con kardex real y entrega: manual, evidencias, limitaciones y conformidad solicitada.

Evidencia técnica disponible

La base revisada contiene 840 registros diarios por categoría, correspondientes a 168 fechas y cinco categorías; el catálogo contiene 203 productos. Son cifras de la versión examinada y deberán recalcularse si cambian las fuentes.

El postest del 17/08 al 15/09/2026 utiliza 150 observaciones. El modelo obtiene MAPE 26,21 % y PMS-7 29,14 % en la misma ventana. Esta comparación retrospectiva no demuestra causalidad ni una reducción real del inventario. El pretest reconstruido anterior tiene MAPE 23,76 % y requiere confirmar el método previo y la fecha real de intervención.

El código de entrenamiento aplica requisitos de historia por categoría y compara candidatos usando WAPE. Las fichas académicas utilizan MAPE; ambos criterios deben explicarse de forma coherente. No se trasladan automáticamente al documento resultados de pruebas de versiones anteriores.

Riesgos y acciones previstas

Inventario demostrativo: obtener kardex conciliado antes de usar ISI y TQS como evidencia. Referencia de junio: validar la definición de VPR y VPM con el docente. Tablas incompletas en pantalla: implementar HU06 y verificar sus exportaciones. Disponibilidad de responsables: confirmar roles y fechas antes de iniciar.

Registro por Sprint

Conservar Sprint Goal, historias seleccionadas, tareas, responsables, impedimentos, pruebas, evidencia de la demostración, observaciones de Review y acción de retrospectiva. Las X del cronograma solo representan planificación. La aceptación y las firmas se completarán al realizar la revisión formal.

TAULLY MARKET E.I.R.L
JAIMES MAYS MIGUEL ANGEL
GERENTE GENERAL

taully

Anexo 4 Evidencia visual y fuentes de verificación

Captura real del programa obtenida durante la verificación previa. La interfaz acredita funciones visibles y un resultado de ejecución; no acredita fechas de Sprints ni conformidad de la empresa.

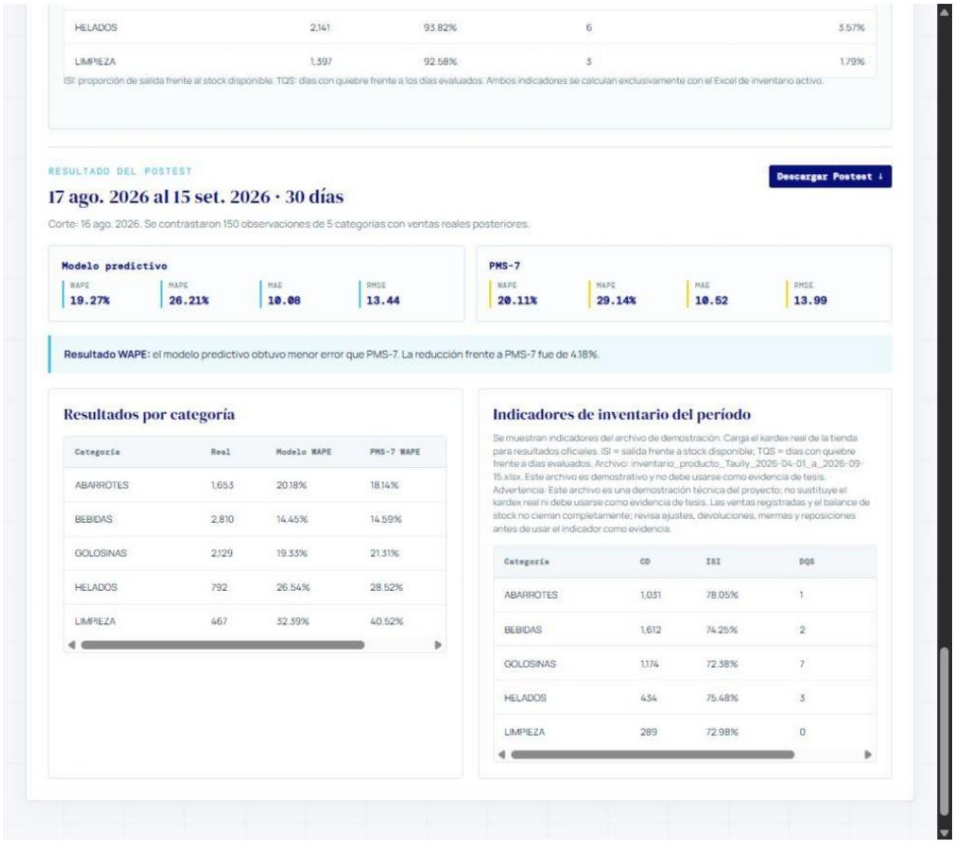


Figura 1. Evaluación retrospectiva del 17 de agosto al 15 de septiembre de 2026. La tarjeta del modelo muestra MAPE 26,21 %. El panel identifica el inventario como demostrativo.

Fuentes utilizadas

Formato institucional PPP1-C1-PRA03; plan previo de evidencia técnica entregado por el practicante; informe LIMA-NORTE_PI_GURRERRO.docx; código de entrenamiento y evaluación en application/services; exportación postest_pronostico_2026-08-17_a_2026-09-15.xlsx; cálculos y guía conservados en outputs/anexo2_30dias_hasta_15septiembre.

TAULLY MARKET E.I.R.L
JAIMES MAYS MIGUEL ANGEL
GERENTE GENERAL

taully

V. ACTIVIDADES PRINCIPALES A REALIZARSE EN LA EMPRESA

PLAN PROPUESTO: Las X indican semanas previstas de trabajo, no actividades ya realizadas. Se organizan seis Sprints de dos semanas para validar y completar el sistema existente. El inicio y fin del plan se definirán con la empresa; las fechas del historial de ventas no son fechas de prácticas.

Las fases de gestión del formato institucional se conservan. Scrum organiza el desarrollo mediante Product Goal, Product Backlog, Sprint Goal, incrementos y eventos de inspección y adaptación. El anexo precisa las entregas, los criterios de aceptación y la evidencia disponible.

DETALLAR LAS ACTIVIDADES	TIEMPO											
FASE / ACTIVIDAD	Mes 1				Mes 2				Mes 3			
SPRINT	Sprint 1		Sprint 2		Sprint 3		Sprint 4		Sprint 5		Sprint 6	
SEMANA	1	2	3	4	5	6	7	8	9	10	11	12
FASE 1. INICIO (PMI)												
1. Identificar necesidades de predicción de ventas y reposición en Taully	X											
2. Identificar usuarios de ventas, compras y responsable de validación	X											
3. Definir valor esperado del pronóstico diario por categoría	X											
4. Acordar objetivos y resultados verificables del sistema	X											
FASE 2. PLANIFICACIÓN (PMI + SCRUM)												
5. Delimitar alcance, fuentes autorizadas y entregables	X	X										
6. Revisar reportes, catálogo, historial y requisitos del panel	X	X										
7. Definir Product Goal para pronóstico y evaluación trazables	X											
8. Detallar historias de usuario y criterios de aceptación	X	X										
9. Priorizar y estimar el Product Backlog con el responsable	X	X										
10. Planificar seis Sprints con entregas y dependencias	X	X										
11. Confirmar roles Scrum, disponibilidad y comunicación	X											
12. Definir calidad, riesgos, fuentes y Definition of Done	X	X										
FASE 3. EJECUCIÓN - SCRUM												
13. Sprint Planning y selección de trabajo según Sprint Goal	X		X		X		X		X		X	
14. Sprint 1: validar alcance, reportes y catálogo maestro	X	X										
15. Sprint 2: comprobar historial y calidad de datos			X	X								
16. Sprint 3: validar entrenamiento por categoría y métricas					X	X						
17. Sprint 4: comprobar pronósticos y exportaciones							X	X				

Anexo 11. Otras evidencias.

Universidad César Vallejo	INFORME DE REVISIÓN EXPEDITA/COMPLETA DE PROYECTOS	Código: F10-PP-PT-02.02 Versión: 00 Fecha: 17-06-2025 Página 1 de 1

Informe de revisión de proyectos de investigación del Comité de Ética en Investigación de la Escuela de Ingeniería de Sistemas

Informe N.° 00340-2026/CEI-EIS

El que suscribe, presidente del Comité de Ética en Investigación de la Escuela de Ingeniería de Sistemas, deja constancia que el proyecto de investigación titulado "Modelo de machine learning para predecir la demanda diaria por categoría de producto en minimarket del distrito de Comas 2026", presentado por los el(los) autor(es) GUERRERO MORA CARLOS DAVID ELIAN, ha pasado una revisión expedita por TAVARA RAMOS ANTHONY PAUL, y se determina que la continuidad para la ejecución del proyecto de investigación cuenta con un dictamen:

(x) Favorable ( ) Desfavorable

30 de junio de 2026

Apellidos y Nombres	Cargo	Código orcid	Firmado electrónicamente por
TAVARA RAMOS ANTHONY PAUL	PRESIDENTE	0000-0002-4159-930X	Firmado electronicamente por ATAVARAR el 30 de junio del 2026 10:27:05
BERMEJO TERRONES HENRY PAÚL	MIEMBRO 05	0000-0002-3348-0181	Firmado electronicamente por HBERMEJOT el 30 de junio del 2026 19:43:59
ROMAN NANO FRANKLIN RODOLFO	MIEMBRO 03	0000-0001-7397-6993	Firmado electronicamente por FROMANN el 30 de junio del 2026 11:54:07

Comité de Ética en Investigación de la Escuela de Ingeniería de Sistemas
Universidad César Vallejo

Escanea el código QR para descargar el informe

NOTA: *Cualquier documento impreso diferente del original y cualquier archivo electrónico que se encuentren fuera del campus virtual Trilce serán considerados como COPIA NO CONTROLADA.*

Anexo 12. Matriz de consistencia

Problemas	Objetivos	Hipótesis	Variables	Dimensiones	Indicador	Metodología
Principal	General	General	Independiente			Tipo de Investigación: Aplicada Enfoque: Cuantitativa Diseño de investigación: preexperimental: Población: totalidad de los registros históricos de ventas e inventario del Minimarket Taully, Comas, correspondientes al período de estudio (abril 2026 – diciembre 2026 Alcance : Nivel predictivo Muestra: censal. Muestreo: No probabilístico por conveniencia.
¿De qué manera un modelo de machine learning permitirá predecir la demanda diaria por categoría de producto en un minimarket de Comas, 2026?	desarrollar y evaluar un modelo de machine learning para predecir la demanda diaria por categoría de producto en un minimarket de Comas, 2026.	se planteó que el desarrollo de un modelo de machine learning permitirá predecir la demanda diaria por categoría de producto en un minimarket de Comas, 2026	Modelo de machine learning Algoritmos computacionales que aprenden patrones de datos históricos para realizar predicciones [1], [4].			
Segundario	Específicas	Específicas	Dependiente			
(P1) ¿cómo se recopilarán y depurarán los datos históricos de ventas e inventario del minimarket para la construcción del modelo predictivo?	(OE1) recopilar y depurar los datos históricos de ventas e inventario del minimarket para la construcción del modelo predictivo.	(HE1) los datos históricos de ventas e inventario del minimarket, una vez depurados y organizados, permitirán identificar patrones de comportamiento de la demanda por categoría de producto.	Demanda diaria por categoría de producto Cantidad de productos vendidos por categoría, influenciada por factores estacionales y externos [1], [3].	Volumen de Demanda	Cantidad Demandada (Unidades) Índice de Salida de Inventario Tasa de Quiebre de Stock	
(P2) ¿qué modelos predictivos de machine learning orientados a series temporales	(OE2) entrenar y comparar el desempeño de diversos algoritmos de machine learning	(HE2) al menos uno de los modelos de machine learning evaluados mostrará un error de				

presentarán un mejor desempeño durante el entrenamiento para la demanda diaria por categoría?	orientados a series temporales para la predicción de la demanda diaria por categoría.	predicción MAE, RMSE y MAPE menor que el método base			Método de Investigación: Hipotético-deductivo Técnica e instrumentos: Análisis documental, ficha de registro, dataset de ventas y reporte de métricas.
(P3) ¿cuál será el nivel de desempeño de los modelos evaluados según las métricas de error MAE, RMSE y MAPE?	(OE3) evaluar el desempeño predictivo de los modelos entrenados utilizando las métricas de error MAE, RMSE y MAPE.	(HE3) el modelo de machine learning con el mejor desempeño predictivo facilitará una mejor planificación del inventario al proporcionar estimaciones diarias por categoría, lo que permitirá reducir los quiebres de stock y el exceso de inventario en el minimarket.	Patrón de Demanda	Estacionalidad	
(P4) ¿de qué manera el modelo seleccionado apoyará la planificación del inventario y la toma de decisiones comerciales del minimarket?	(OE4) analizar la contribución predictiva del modelo seleccionado en la planificación del inventario y la toma de decisiones comerciales del minimarket.	(HE4) La implementación del modelo seleccionado permitirá optimizar la planificación del inventario al reducir los quiebres de stock y el exceso de inventario en el minimarket.	Precisión del Pronóstico	Error de Pronóstico	

Anexo 13. Reporte de similitud del software Turnitin.